INFORME FINAL

Implementación de Modelo de Machine Learning en Azure ML

Predicción de Fuga de Clientes mediante AutoML

Especialidad:	Data Analytics Multicloud Pedan 6
Tema del Proyecto:	Predicción de Fuga de Clientes mediante AutoML en Azure ML
Estudiante:	Gomez Mendoza Franklin Kevin

1. Descripción del Dataset

Para este proyecto seleccioné el dataset "Telco Customer Churn" disponible en la plataforma Kaggle, un recurso ampliamente utilizado en la industria de las telecomunicaciones para estudiar la retención y pérdida de clientes. A continuación, describo sus características principales:

- **Objetivo del Modelo:** El objetivo central del modelo es clasificar y predecir si un cliente abandonará los servicios de la empresa —denominado churn o fuga— basándose en su comportamiento histórico y sus atributos demográficos.
- **Volumen de Datos:** El dataset contiene 7,044 registros distribuidos de la siguiente manera: una porción fue reservada exclusivamente para inferencia local (testeo), mientras que el resto se utilizó para el entrenamiento en la nube de Azure.
- **Características Principales:** El conjunto cuenta con 21 columnas en su estado original, que incluyen variables demográficas (género, si es adulto mayor), servicios contratados (internet, soporte técnico, streaming) e información de la cuenta del cliente (tipo de contrato, método de pago y cargos mensuales).
- **Variable Objetivo (Target):** La columna "Churn" (Valores: True / False) actúa como variable objetivo, convirtiendo este problema en una tarea de Clasificación Binaria.

2. Pasos de Desarrollo y Configuración en Azure ML

El desarrollo completo del modelo se llevó a cabo utilizando Azure Machine Learning Studio, aprovechando su infraestructura de cómputo en la nube y la herramienta de Automated Machine Learning (AutoML) para la selección y optimización automática de algoritmos.

2.1. Ingesta y Preparación de Datos

Como primer paso, cargué el dataset como un Activo de Datos (Data Asset) de tipo tabular dentro del Workspace de Azure ML. Este registro permite gestionar el versionado y la trazabilidad del dato a lo largo de todo el experimento.

INTERNAL

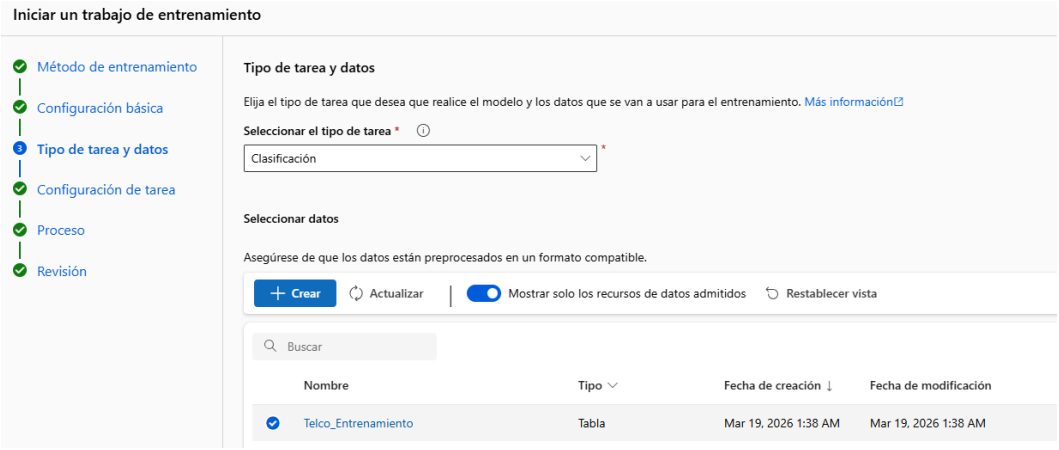

Figura 1. Registro del dataset tabular en Azure ML.

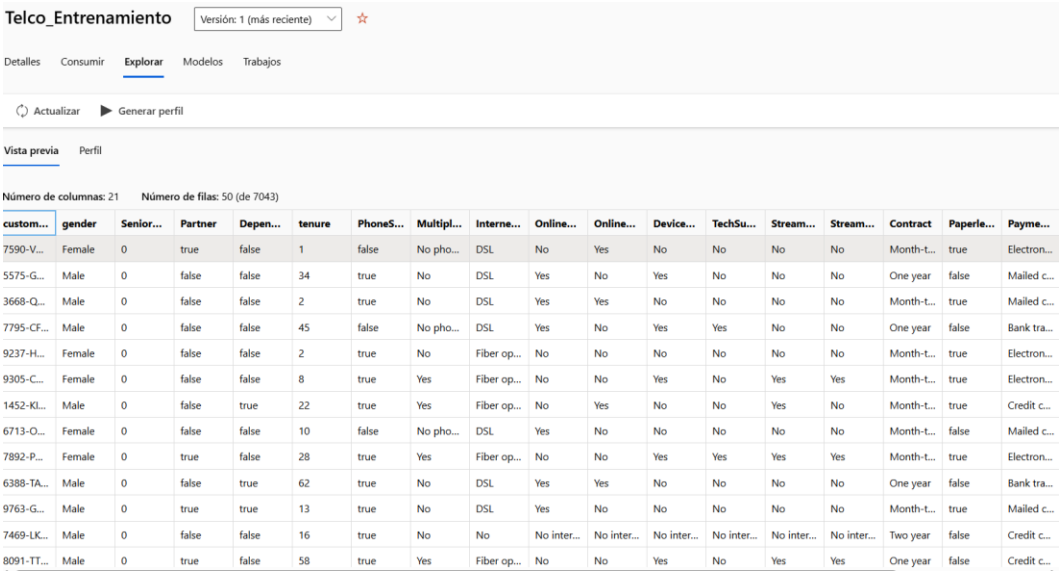

custom...	gender	Senior...	Partner	Depen...	tenure	PhoneS...	Multipl...	Interne...	Online...	Online...	Device...	TechSu...	Stream...	Stream...	Contract	Paperle...	Payme...
7590-V...	Female	0	true	false	1	false	No pho...	DSL	No	Yes	No	No	No	No	Month-t...	true	Electron...
5575-G...	Male	0	false	false	34	true	No	DSL	Yes	No	Yes	No	No	No	One year	false	Mailed c...
3668-Q...	Male	0	false	false	2	true	No	DSL	Yes	Yes	No	No	No	No	Month-t...	true	Mailed c...
7795-CF...	Male	0	false	false	45	false	No pho...	DSL	Yes	No	Yes	Yes	No	No	One year	false	Bank tra...
9237-H...	Female	0	false	false	2	true	No	Fiber op...	No	No	No	No	No	No	Month-t...	true	Electron...
9305-C...	Female	0	false	false	8	true	Yes	Fiber op...	No	No	Yes	No	Yes	Yes	Month-t...	true	Electron...
1452-KI...	Male	0	false	true	22	true	Yes	Fiber op...	No	Yes	No	No	Yes	No	Month-t...	true	Credit c...
6713-O...	Female	0	false	false	10	false	No pho...	DSL	Yes	No	No	No	No	No	Month-t...	false	Mailed c...
7892-P...	Female	0	true	false	28	true	Yes	Fiber op...	No	No	Yes	Yes	Yes	Yes	Month-t...	true	Electron...
6388-TA...	Male	0	false	true	62	true	No	DSL	Yes	Yes	No	No	No	No	One year	false	Bank tra...
9763-G...	Male	0	true	true	13	true	No	DSL	Yes	No	No	No	No	No	Month-t...	true	Mailed c...
7469-LK...	Male	0	false	false	16	true	No	No	No inter...	No inter...	No inter...	No inter...	No inter...	No inter...	Two year	false	Credit c...
8091-TT...	Male	0	true	false	58	true	Yes	Fiber op...	No	No	Yes	No	Yes	Yes	One year	false	Credit c...

Figura 2. Registros subidos confirmados tras la ejecución del pipeline de ingesta.

2.2. Configuración del Trabajo de Automated ML (AutoML)

Una vez registrado el dataset, procedí a configurar el experimento de Machine Learning Automatizado con los siguientes parámetros técnicos:

- **Tipo de Tarea:** Se definió la tarea como Clasificación, dado que la variable objetivo es de naturaleza binaria (True / False).
- **Columna de Destino:** Se estableció la columna "Churn" como variable a predecir.
- **Ingeniería de Características:** Se realizó un paso crítico de ingeniería de características al excluir explícitamente la columna "customerID". Esta decisión técnica es fundamental: al ser un código alfanumérico único por cliente, incluirlo podría inducir al modelo a encontrar patrones espurios, lo que derivaría en sobreajuste (overfitting) y haría el modelo inútil en producción.
- **Cómputo en la Nube:** Se aprovisionó un clúster de proceso dedicado (Compute Cluster) para paralelizar el entrenamiento de múltiples algoritmos de forma simultánea, reduciendo el tiempo total del experimento.

INTERNAL

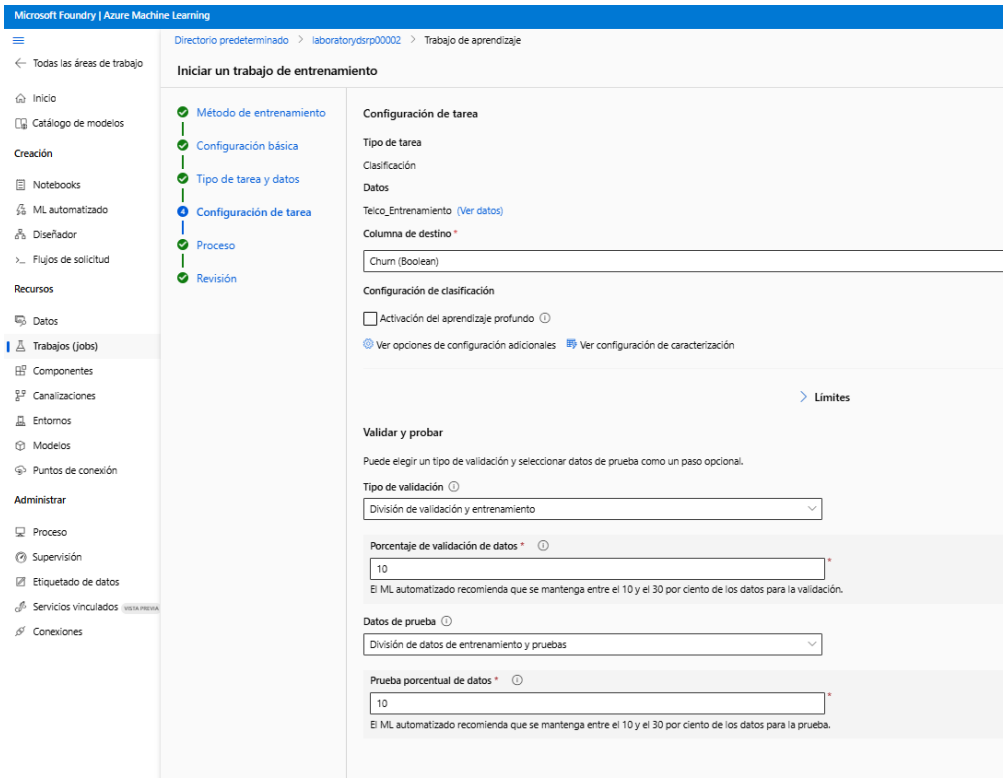

Figura 3. Configuración del experimento de AutoML en Azure ML Studio.

3. Resultados e Interpretación del Desempeño del Modelo

Una vez finalizado el trabajo de AutoML, Azure evaluó múltiples algoritmos e iteraciones de forma automática. El modelo que demostró el mejor rendimiento global fue una Regresión Logística con preprocesamiento de estandarización (StandardScalerWrapper + LogisticRegression).

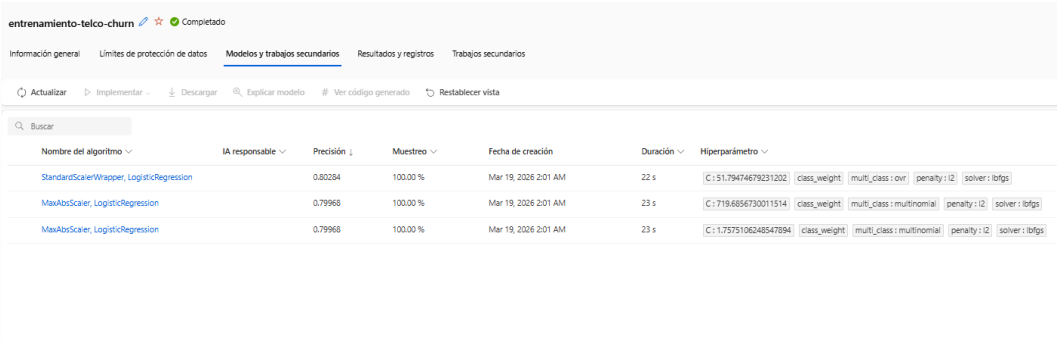

Figura 4. Algoritmo ganador seleccionado por AutoML: Regresión Logística con estandarización.

3.1. Métricas de Desempeño del Modelo Ganador

La selección de Regresión Logística representa una ventaja significativa para el negocio: es un modelo altamente interpretable, lo que facilita la comunicación de resultados a stakeholders no técnicos. Las métricas obtenidas fueron las siguientes:

INTERNAL

Métrica	Valor Obtenido	Interpretación
Accuracy (Precisión Global)	**0.8028 (80.28%)**	El modelo clasifica correctamente a 8 de cada 10 clientes.
AUC Macro (Área bajo la Curva ROC)	**0.8580 (85.80%)**	Excelente capacidad de discriminación entre cliente leal y desertor.
F1-Score Macro	**0.7360 (73.60%)**	Balance sólido entre Precisión y Exhaustividad (Recall).

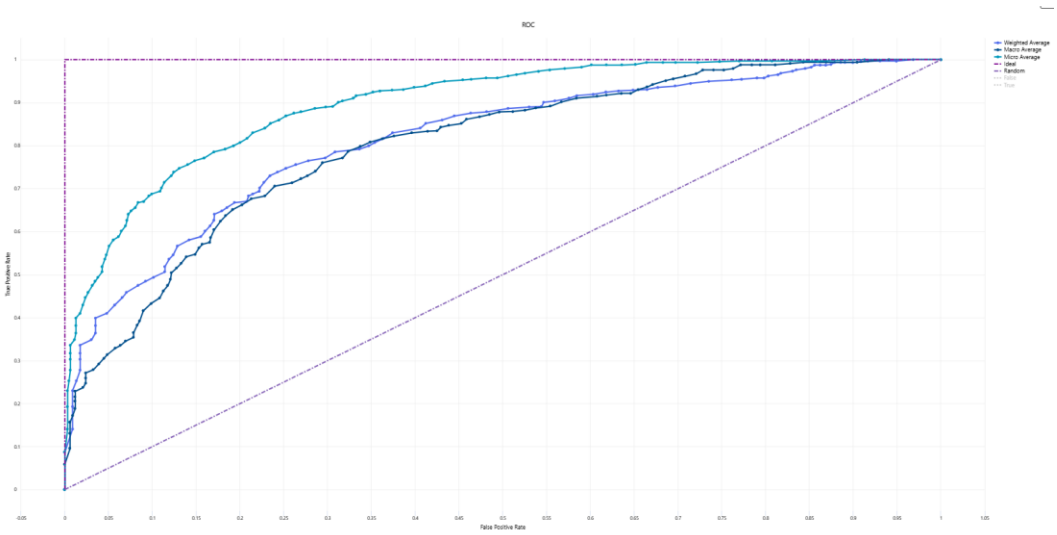

Figura 5. Curva ROC del modelo, con un AUC = 0.857, indicando una alta capacidad discriminatoria.

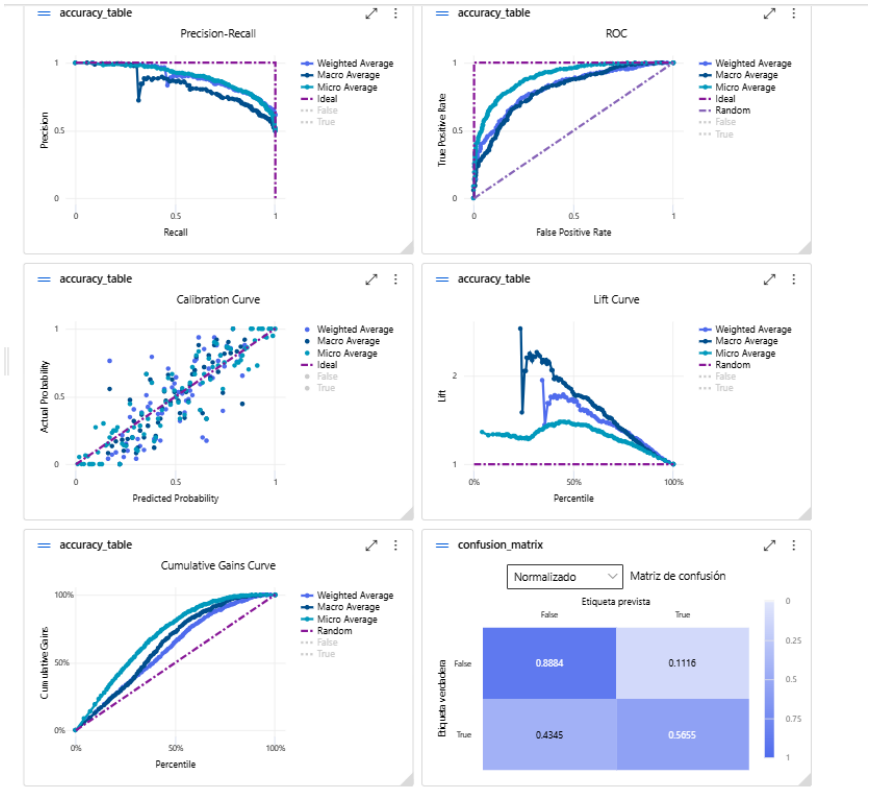

Figura 6. Tablas de precisión que reflejan la distribución de las predicciones del modelo.

INTERNAL

3.2. Análisis desde la Perspectiva de Negocio

Más allá de las métricas técnicas, interpreto los resultados en términos de impacto operativo:

- **Fortaleza Principal:** El modelo es 2 veces más efectivo que el azar al momento de priorizar el 30% de clientes con mayor riesgo de abandono, lo cual es valioso para campañas de retención focalizadas.
- **Área de Mejora:** Las curvas ROC y de Calibración confirman una base técnica sólida; sin embargo, la matriz de confusión normalizada revela un sesgo hacia la clase mayoritaria (clientes que permanecen), lo cual es un patrón esperable en datasets desbalanceados como el de churn.
- **Riesgo Identificado:** El modelo actualmente no detecta al 43.5% de los desertores reales, representando un costo de oportunidad crítico en términos de ingresos no gestionados. Para versiones futuras, recomendaría aplicar técnicas de balanceo de clases (SMOTE o ajuste de umbrales de clasificación) para capturar más casos de fuga sin incrementar excesivamente los costos de retención.
- **Recomendación Operativa:** El modelo es apto para pilotos comerciales focalizados en segmentos de alta probabilidad de churn, donde el retorno de inversión por cliente retenido es mayor.

4. Despliegue y Pruebas Locales desde Visual Studio Code

Para hacer el modelo consumible desde aplicaciones externas, lo desplegué como un Punto de Conexión en Tiempo Real (Real-time Endpoint) en Azure ML. Este proceso genera automáticamente una API REST protegida por un token de autorización, habilitando el modelo para inferencias bajo demanda.

INTERNAL

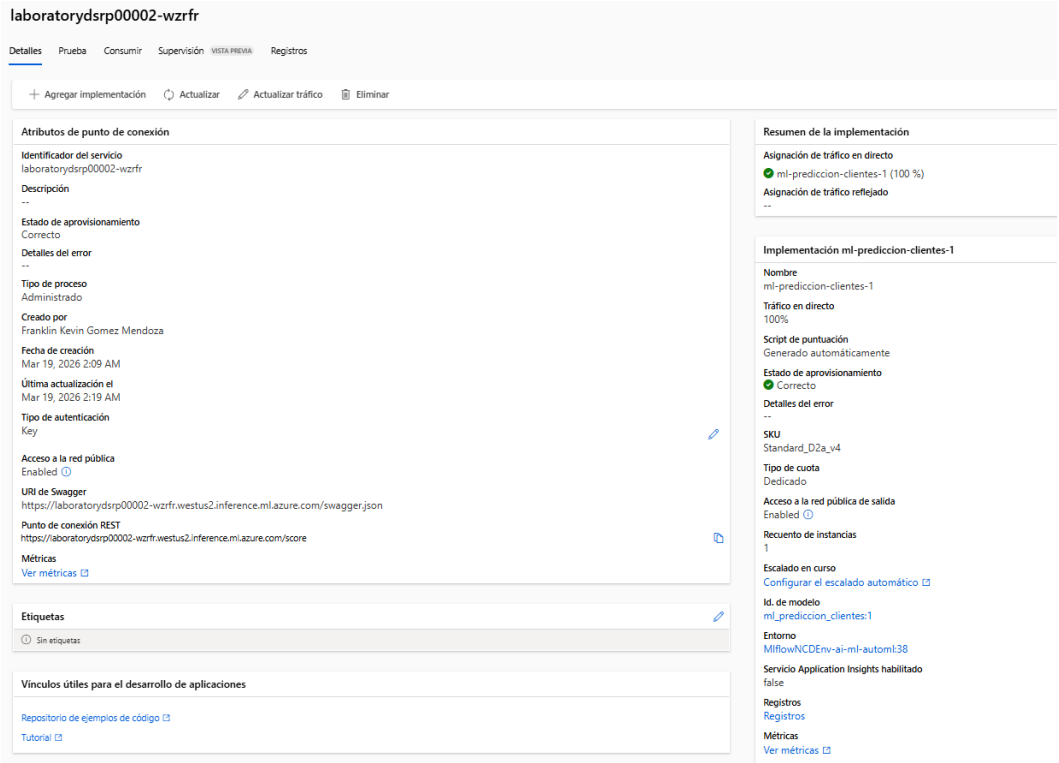

Figura 7. Endpoint en tiempo real desplegado y activo exitosamente en Azure ML.

4.1. Integración y Consumo desde Visual Studio Code

Para validar la integración en un entorno multicloud y local, configuré un entorno virtual con Conda y Python en Visual Studio Code. El procedimiento de prueba fue el siguiente:

- **Preparación del Conjunto de Prueba:** Se separó previamente un conjunto de registros del dataset original como muestra de prueba, asegurando que el modelo no hubiera "visto" estos datos durante el entrenamiento (conjunto de holdout).
- **Implementación del Script de Inferencia:** Se programó un script en Python utilizando la librería estándar urllib.request para construir y enviar el payload en formato JSON hacia el endpoint de Azure, incluyendo el token de autenticación en los headers de la solicitud HTTP.

INTERNAL

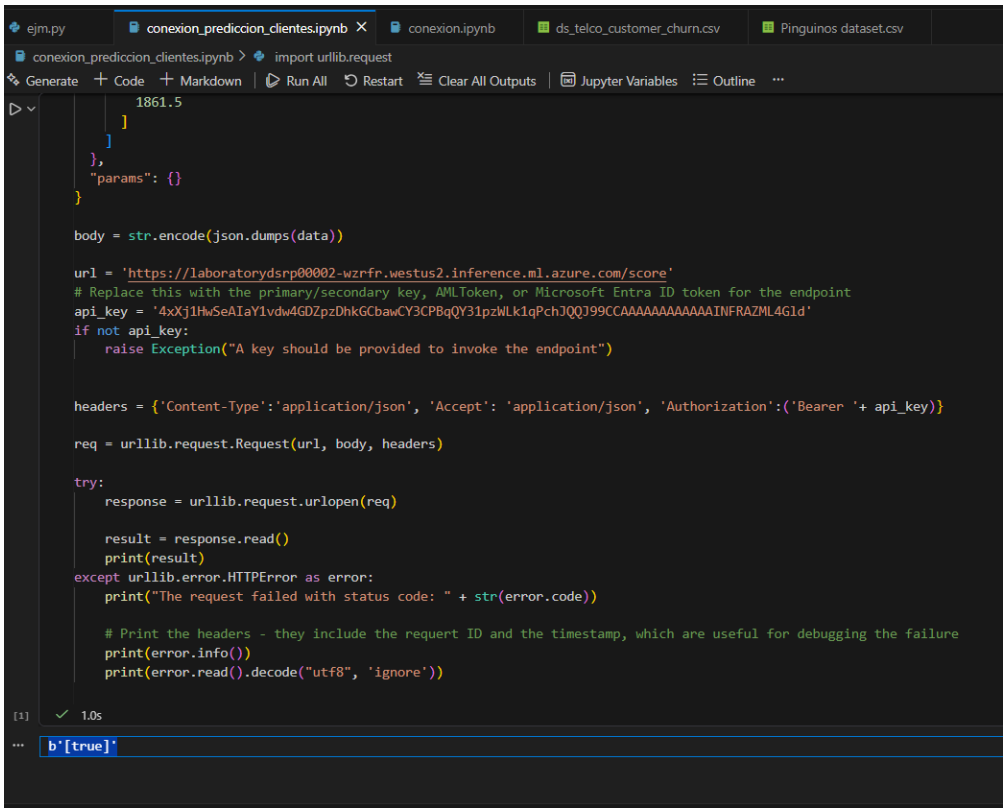

Figura 8. Inferencia exitosa ejecutada desde VS Code, mostrando la predicción del modelo.

4.2. Interpretación del Resultado de la Prueba

La prueba de integración fue exitosa. Al enviar los datos de las 19 características del cliente —excluyendo deliberadamente el "customerID" y la variable objetivo "Churn"— el modelo devolvió la predicción [true], es decir, este cliente tiene una alta probabilidad de abandonar la empresa.

Este resultado valida la integración de extremo a extremo (End-to-End): el código ejecutado localmente logró comunicarse con el servicio desplegado en la nube, y el modelo infirió correctamente que, dado el perfil del cliente (características como tipo de contrato y cargos mensuales), existe un riesgo significativo de churn. Esto demuestra que el pipeline completo —desde el entrenamiento en Azure hasta la inferencia local— funciona de manera integrada y reproducible.

5. Conclusiones

A partir del desarrollo de este proyecto, extraigo las siguientes conclusiones:

1. **Eficacia de AutoML para la selección de algoritmos.** Azure Machine Learning automatizó el proceso iterativo de selección y evaluación de modelos, eligiendo una Regresión Logística como el algoritmo de mejor rendimiento. Esto confirma un principio fundamental en la práctica del análisis de datos: los modelos más complejos no siempre son los más adecuados. Un

INTERNAL

modelo tradicional bien preprocesado puede ofrecer una precisión excelente junto con una transparencia que facilita la toma de decisiones empresariales.

2. **Importancia crítica de la curación de datos.** La decisión de excluir tempranamente la variable "customerID" demostró ser un paso esencial en la configuración. Este tipo de decisión —aparentemente simple— tiene un impacto directo en la calidad del aprendizaje del modelo, evitando el sobreajuste y garantizando que las predicciones se basen en patrones reales de comportamiento.
3. **Validación de la operacionalización del modelo.** La transición exitosa del entrenamiento a producción, validada mediante el despliegue del endpoint en Azure y el consumo desde VS Code, demuestra la viabilidad de integrar modelos de Machine Learning en flujos de trabajo reales. Esta capacidad de operacionalización es, desde mi perspectiva, la habilidad más valiosa de un analista de datos en un entorno empresarial moderno.
4. **Oportunidades de mejora identificadas.** El análisis de la matriz de confusión reveló que el modelo presenta dificultades para detectar correctamente a los clientes que sí abandonan (falsos negativos). Como trabajo futuro, recomendaría explorar técnicas de balanceo de clases y ajuste del umbral de clasificación para mejorar el Recall, convirtiendo el modelo en una herramienta aún más efectiva para la gestión proactiva de la retención de clientes.

INTERNAL